

PROJETO INTEGRADOR DE CIÊNCIA DE DADOS: PREVISÃO DO ESTADO CLÍNICO DE CAVALOS COM CÓLICA UTILIZANDO MODELOS DE CLASSIFICAÇÃO SUPERVISIONADA

Lucas Rivelto C. Almeida¹, Thiago Cavalcante dos Santos²

RESUMO

Este trabalho visa demonstrar a aplicação de Machine Learning (aprendizado de máquina) com o objetivo de prever o estado clínico de cavalos com dores abdominais classificadas como Cólica Equina utilizando a base de dados UCI Horse Colic Dataset composto por 299 registros disponibilizada no Kaggle. Foram realizadas análise exploratória, tratamento de valores ausentes, transformação de variáveis categóricas, construção de pipelines e comparação entre Regressão Logística, Decision Tree, Random Forest e SVC. A Regressão Logística de padrão $C=1.0$ apresentou a melhor acurácia dentre os modelos anteriores, porém com ajustes no código e atribuindo $C=0.1$ obtivemos resultados superiores, chegando a 68% de acurácia em um conjunto de dados com 30% dos valores faltantes, evidenciando ser a abordagem mais adequada para a base analisada. O Pipeline de pré-processamento contou com imputação de mediana para variáveis numéricas, imputação por moda e codificação One-Hot para variáveis categóricas em conjunto ao tratamento de dados ausentes para maior aproveitamento dos modelos de classificação.

Palavras-chave: Machine learning. Cólica equina. Kaggle. Regressão logística. Pipelines.

1 INTRODUÇÃO

A cólica equina abrange um conjunto perigoso de distúrbios abdominais, constituindo uma das principais emergências veterinárias em frequência e fatalidade de grandes animais. A previsão do estado clínico pode auxiliar a tomada de decisão sobre o tratamento, que demanda triagem e avaliação rápida dos múltiplos indicadores fisiológicos dos equinos. Diante da severidade da síndrome, a rapidez e a precisão no diagnóstico inicial são determinantes para a sobrevivência do animal, tornando o ambiente de atendimento em um cenário crítico que exige respostas imediatas e assertivas baseadas em sinais clínicos de maior complexidade.

Nesse contexto, o uso de modelos de previsão baseados em machine learning se torna um grande aliado no apoio à decisão clínica, aliviando o volume expressivo de dados vindos de prontuários de atendimento e exames de emergência, permitindo identificar padrões

¹ Discente do Curso de Engenharia de Software da Universidade Federal de Rondonópolis (UFR) – ICEN. E-mail: lucas.rivelo@aluno.ufr.edu.br

² Discente do Curso de Engenharia de Software da Universidade Federal de Rondonópolis (UFR) – ICEN. E-mail: t.cavalcante@aluno.ufr.edu.br

ocultos e estimar prognósticos a partir dos dados obtidos, transformando-os em previsões estatísticas.

O objetivo central deste trabalho é identificar o modelo que melhor responde a pergunta principal da pesquisa: É possível prever o estado clínico [*Lived*, *Euthanized* ou *Died*] de um cavalo a partir das informações obtidas durante o atendimento presentes no dataset? O foco deste estudo é desenvolver, testar, otimizar e comparar algoritmos de classificação em busca da abordagem mais adequada e robusta diante de um conjunto de dados com uma alta taxa de valores omitidos.

2 METODOLOGIA

2.1 Base de Dados

Os dados utilizados neste estudo são provenientes da base de dados *UCI Horse Colic Dataset* da Universidade da Califórnia em Irvine obtida através da plataforma Kaggle. O conjunto possui 299 instâncias de registros clínicos de equinos com internações por cólica com descrições em 28 atributos estruturados, trazendo parâmetros quantitativos e categóricos de natureza clínica e qualitativa como frequência cardíaca, frequência respiratória e aparência do abdômen. A variável determinante que usada como alvo é chamada de Outcome e apresenta três classes distintas: *Lived* (59,5%), *Died* (25,8%) e *Euthanized* (14,7%) evidenciando um desbalanceamento moderado com um desvio-padrão de 19,05 pontos percentuais.

O principal desafio desta base é o alto índice de valores ausentes (*missing values*), alcançando aproximadamente 30% de faltas distribuídas pelas colunas de maneira heterogênea, em evidência, as variáveis *nasogastric_reflux_ph*, *abdomo_appearance* e *abdomo_protein* que apresentaram mais de 55% de registros faltantes, necessitando de uma estratégia rigorosa de tratamento.

2.2 Pré-Processamento e Pipelines

Para garantir a robustez e integridade dos modelos de classificação, foi construído um fluxo de processamento através da biblioteca Scikit-Learn. A primeira etapa consistiu no

tratamento dos dados ausentes e das colunas mais afetadas, removendo a variável administrativa identificadora *hospital_number* por não apresentar poder preditivo, seguido do descarte de *nasogastric_reflux_ph* e *abdomo_protein* em razão do volume excessivo de ausências. Para encerrar os tratamentos manuais, optou-se por manter *abdomo_appearance* através de uma categorização das faltas, denominando-as como *Missing*, decisão fundamentada no fato de que a ausência não afetou, em maioria, os animais mortos ou sacrificados.

Para os demais atributos, adotou-se a estratégia de uso da mediana como valor selecionado para variáveis numéricas como forma de assegurar coerência com menos instâncias discrepantes chamadas outliers. Para as variáveis categóricas, a moda ficou responsável pelos valores omitidos, preenchendo com o valor mais frequente da coluna.

Na sequência, realizou-se a conversão das variáveis categóricas em representações binárias através do componente *OneHotEncoder* e sua codificação, com o intuito de evitar a redundância estatística na classificação multiclasse. Em um segundo pipeline, atribui-se a partícula *drop='first'* para SVC, descartando a primeira coluna preenchida por zeros.

A divisão treino/teste seguiu a proporção 75/25 pela variável-alvo, garantindo representatividade proporcional das três classes nos subconjuntos. O parâmetro *class_weight='balanced'* foi utilizado em todos os modelos para compensar o desbalanceamento entre as classes.

2.3 Modelos Avaliados

O projeto é estruturado em classificação multiclasse buscando o desfecho dos equinos da base de dados. Para identificar se sobrevivência, óbito ou eutanásia ocorreram, foram escolhidos quatro modelos distintos para selecionar a abordagem mais adequada para o problema em questão.

- Árvore de Decisão (*DecisionTreeClassifier*): Modelo não linear baseado em regras de decisão estruturadas em ramificações;
- Random Forest (*RandomForestClassifier*): Algoritmo de aprendizado de conjunto (*ensemble*) que combina múltiplas árvores de decisão independentes para reduzir a variância e evitar o *overfitting*;
- SVC com kernel RBF ($C=1.0$): Classificador que busca melhorar o hiperplano de separação entre as classes;

- Regressão Logística: Modelo linear utilizado para mensurar a probabilidade dos eventos acontecerem a partir de combinações dos atributos.

3 DESENVOLVIMENTO E EXPERIMENTOS

Os experimentos foram realizados no ambiente Google Colab, na linguagem de Python 3 e utilizando as bibliotecas de Scikit-Learn, pandas, numpy, matplotlib e seaborn. Todo o fluxo de pré-processamento foi integrado ao pipeline de treinamento para evitar vazamento de dados entre treino e teste.

Na análise exploratória, no que dizia respeito às correlações das variáveis numéricas com o alvo, destaca-se que as features *total_protein* e *pulse* possuem o maior poder de separação entre vivo, morto ou sacrificado, seguido de *packed_cell_volume*, *peristalsis* e *capillary_refill_time*.

Após a avaliação inicial dos quatro modelos de classificação, o Pipeline de Regressão Logística obteve o melhor desempenho nos parâmetros de avaliação: acurácia, precisão, recall e F1-score, sendo o modelo escolhido para a análise manual de alternância do fator C, variando entre 0,01 e 5,0 em pré-processamentos alternados com e sem a presença de *drop='first'* no one-hot encoder, possibilitando comparar os efeitos da remoção da coluna de valores zerados.

4 RESULTADOS E DISCUSSÃO

A Tabela 1 apresenta os resultados dos quatro modelos avaliados na configuração inicial (C=1,0 para a Regressão Logística e SVM) e na variação de fatores para a Regressão Logística.

Modelo	Acurácia	Precisão	Recall	F1-score
Regressão Logística C=0.1 <i>drop='first'</i>	0.680	0.690	0.680	0.681
Regressão Logística Padrão	0.666	0.688	0.666	0.67

Random Forest	0.6	0.562	0.6	0.573
Decision Tree	0.546	0.539	0.546	0.542
SVC 'rbf'	0.373	0.817	0.37333	0.398

A Regressão Logística ($C=1,0$) apresentou o melhor desempenho entre os modelos da avaliação inicial, registrando accuracy de 66,6% e F1-score de 67,0%. Em contraponto, o SVM, apesar de alcançar uma maior precisão entre todos os modelos (81,8%), obteve acurácia de apenas 37,3%, o que demonstra a dificuldade em determinar corretamente o estado clínico do animal.

A Regressão Logística com $C=0,1$, utilizando o pré-processamento padrão sem `drop='first'`, foi a configuração que produziu o melhor resultado do experimento: accuracy de 68,0%, precision de 69,6%, recall de 68,0% e F1-score de 68,1%. O valor reduzido de C aplica uma regularização mais forte, o que se mostrou vantajoso dado o tamanho enxuto do dataset de apenas 299 amostras, evitando que o modelo se ajuste excessivamente aos dados de treino.

A análise da matriz de confusão evidencia assimetria de desempenho entre as classes. O modelo acerta 31 de 45 casos de *lived* e 15 de 19 casos de *died*, mas apresenta baixo desempenho para os casos de *euthanized*. Esse resultado se justifica pelo fator humano que entra em notoriedade, pois a decisão de eutanasiar um animal envolve questões pessoais do dono como condição financeira e vínculo afetivo.

Outros algoritmos foram testados, como KNN, MLP, Gradient Boosting e variações de Random Forest, porém nenhum superou os resultados obtidos. Em datasets pequenos e com muitos dados ausentes, modelos mais simples tendem a ter melhor capacidade de generalização do que modelos mais complexos.

5 CONCLUSÃO

O presente estudo encerrou-se cumprindo o objetivo geral do trabalho em desenvolver, com aprendizado de máquina, um projeto de construção de um modelo preditivo do estado clínico de equinos com cólica obtendo um desempenho razoável (68%) em uma base diminuta com 30% dos valores faltantes. Os experimentos práticos, matemáticos e estatísticos demonstraram que há possibilidade viável de estimar e prever cenários de sobrevivência,

morte ou sacrifício utilizando parâmetros fisiológicos classificados e obtidos durante a avaliação do animal. A Regressão Logística com regularização focada em moderação, evitando variações bruscas de resultados (com o parâmetro $C=0,1$) superou algoritmos mais complexos, reforçando a adequação de modelos simples em problemas adequados.

A metodologia estruturada a partir do ciclo CRISP-DM se mostrou fundamental para contornar as imperfeições presentes no conjunto de dados. O descarte (drop) consciente e cuidadoso das variáveis ruidosas ou de caráter administrativo, somado a criação de novas classes e a seleção de moda e mediana para os valores faltantes proporcionou um tratamento íntegro na modelagem do projeto.

Como limitação principal, destaca-se a dificuldade de modelar adequadamente a classe *euthanized*, cujo desfecho depende de variáveis não clínicas ausentes no dataset, que porventura apresenta uma parte significativa faltante. Outras barreiras que corroboraram para a complexidade do algoritmo foram o tamanho da amostra escolhida, que não era de grande expressividade, e atributos com correlação considerável com as outras colunas, mas com alto índice de instâncias faltantes, necessitando de descarte.

Para trabalhos futuros, sugere-se a expansão do volume de registros para melhor entendimento do algoritmo com investigações de técnicas mais robustas de balanceamento de classes. Em suma, o fluxo do trabalho expõe um pontapé inicial promissor para o desenvolvimento de um suporte à tomada de decisão na medicina veterinária de grandes animais.

REFERÊNCIAS

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273-297, 1995.

DUA, D.; GRAFF, C. **UCI Machine Learning Repository**. Irvine: University of California, 1987. Disponível em: <https://archive.ics.uci.edu/ml>. Acesso em: jun. 2025.

HOSMER, D. W.; LEMESHOW, S.; STURDIVANT, R. X. **Applied Logistic Regression**. 3. ed. New Jersey: Wiley, 2013.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

TUKEY, J. W. **Exploratory Data Analysis**. Reading: Addison-Wesley, 1977.

UNIVERSIDADE DA CALIFÓRNIA EM IRVINE (UCI). **Horse Colic Data Set**. UCI Machine Learning Repository, 1989. Disponível em: <https://archive.ics.uci.edu/dataset/47/horse+colic>. Acesso em: 29 jun. 2026.

VIEIRA, P. de A. **Introdução a Machine Learning: Regressão com dados de imóveis de Mato Grosso**. Rondonópolis: Instituto de Ciências Exatas e Naturais - UFR, 2026. Notas de aula/Slides.

VIEIRA, P. de A. **Introdução a Machine Learning: Classificação**. Rondonópolis: Instituto de Ciências Exatas e Naturais - UFR, 2026. Notas de aula.

VIEIRA, P. de A. **Sessão de EDA estruturada e visualização (com integração de dados)**. Rondonópolis: Instituto de Ciências Exatas e Naturais - UFR, 2026. Slides.

YASAR, H. **Horse Survival Dataset**. Kaggle, 2022. Disponível em: <https://www.kaggle.com/datasets/yasserh/horse-survival-dataset>. Acesso em: jun. 2025.